

Lista de Exercícios: Revisão Ativa de Estatística Exploratória

CE009 - Introdução à Estatística | Abordagens Conceituais, Gráficas e Analíticas

Departamento de Estatística (DEST) - UFPR

09/09/2026

Contents

Apresentação	1
Bloco A: Questões de Avaliação e Desafio	1
Bloco B: Gabarito Comentado e Resoluções	6
Implementação Prática e Simulações no R	10

Apresentação

Esta lista de exercícios foi projetada como material de revisão ativa.

Diferente do formato convencional de prova escrita (que exige cálculos aritméticos repetitivos a partir de pequenos conjuntos de dados brutos), esta lista prioriza a **interpretação crítica de delineamentos amostrais, a análise de propriedades analíticas de medidas descritivas, a leitura de representações gráficas bivariadas e a investigação lógica de dependência e associação**.

O objetivo é desenvolver o raciocínio estatístico rigoroso, preparando os estudantes para enfrentar problemas reais de modelagem e ensino de dados.

Bloco A: Questões de Avaliação e Desafio

QUESTÃO 1: Crítica de Planos Amostrais e Delineamento de Estudos

A coleta ética e metodologicamente correta de dados é o pilar de qualquer inferência estatística válida. Avalie criticamente os cenários de pesquisa descritos a seguir:

Cenário I: Com o objetivo de estudar a satisfação dos funcionários de uma grande corporação de tecnologia quanto às suas condições de trabalho e infraestrutura, a diretoria optou por realizar uma pesquisa interna. Por questões de praticidade, o setor de Recursos Humanos indicou, de forma intencional e sem sorteio, um grupo de indivíduos que considerava “altamente representativo” das diversas áreas para responder ao questionário.

Cenário II: Para monitorar a emissão de gases poluentes e a conformidade ambiental de veículos em uma rodovia estadual de grande movimento, uma agência reguladora posicionou uma barreira de fiscalização em um sábado específico, inspecionando exaustivamente todos os automóveis que por ali passaram no intervalo estrito das 14:00 às 14:30 horas.

Cenário III: Um pesquisador deseja avaliar a eficácia de um novo método de ensino interativo de geometria espacial comparado ao método tradicional. Para isso, ele selecionou duas turmas de ensino médio de uma escola. Na Turma A (matutino), ele aplicou o método interativo com uso de softwares de modelagem 3D. Na Turma B (vespertino), ele ministrou as aulas usando o quadro negro e giz tradicional. Ao final do bimestre, aplicou a mesma prova escrita para ambas as turmas.

Itens a serem respondidos: a) Classifique os métodos de amostragem propostos nos **Cenários I e II** em probabilísticos ou não-probabilísticos, identificando o nome exato da técnica de amostragem utilizada em cada caso. Apresente uma crítica metodológica detalhada para cada plano, apontando os potenciais vícios de seleção (vieses) que podem comprometer a generalização dos resultados para as respectivas populações de interesse.

b) Proponha um plano de amostragem probabilística alternativo e metodologicamente robusto para o **Cenário I**, explicando como realizá-lo passo a passo utilizando o cadastro de funcionários da corporação.

c) Classifique o delineamento metodológico do **Cenário III** em *estudo observacional* ou *experimento controlado/planejado*. Discuta se a comparação das médias de notas entre as duas turmas permite estabelecer de forma cientificamente válida uma relação de causa e efeito direta entre o método de ensino interativo e o rendimento escolar dos alunos, identificando potenciais variáveis de confusão (*fatores de confusão*).

d) Classifique as seguintes variáveis de interesse coletadas nessas pesquisas em seu respectivo nível de mensuração (Qualitativa Nominal, Qualitativa Ordinal, Quantitativa Discreta ou Quantitativa Contínua):
1. Número de viagens de ônibus interestaduais realizadas por um usuário na última semana. 2. Nível de satisfação com o ambiente corporativo (Insatisfeito, Neutro, Satisfeito). 3. Número de identificação funcional impresso no crachá do empregado. 4. Concentração de monóxido de carbono (CO) emitido pelo escapamento do veículo (em partes por milhão - ppm).

QUESTÃO 2: Propriedades Analíticas e Robustez das Medidas Descritivas

A compreensão matemática profunda das estatísticas de posição e dispersão exige o conhecimento de seu comportamento sob outliers e transformações geométricas de translação e escala.

Considere que um algoritmo de otimização numérica gerou um conjunto de dados brutos correspondente ao tempo de processamento (em milissegundos) para n instâncias de teste, denotado por $x_1, x_2, \dots, x_n$. Sabe-se que a média aritmética deste conjunto é $\bar{x} = 80$ ms, o desvio padrão amostral é $s_x = 10$ ms, e a mediana é $md_x = 75$ ms.

Itens a serem respondidos: a) Suponha que, devido a uma falha de conexão de rede de longa latência na última execução, a maior observação observada do conjunto (que era de 110 ms) foi incorretamente registrada e multiplicada por 10, passando a ser 1100 ms (caracterizando um outlier extremo na cauda superior). * Explique, sem realizar cálculos numéricos diretos, se a **Mediana** sofrerá alguma alteração após este erro de registro. Justifique sua resposta com base na propriedade de robustez das separatrizes. * Discuta analiticamente o impacto dessa falha de registro sobre a **Média Aritmética**, o **Desvio Padrão** e a **Amplitude Total**. Qual dessas estatísticas de centro (Média ou Mediana) representa de forma mais fidedigna a massa principal de dados sob a presença deste outlier?

b) Para fins de relatórios acadêmicos, os tempos de processamento precisam ser convertidos para uma nova escala de apresentação. A transformação linear adotada é dada pela equação:

$$y_i = 4x_i - 20, \quad \forall i = 1, \dots, n$$

Demonstre analiticamente (através das propriedades algébricas dos operadores de somatório e esperança empírica) e calcule os novos valores para: 1. A nova média aritmética ($\bar{y}$). 2. O novo desvio padrão amostral (s_y). 3. A nova variância amostral (s_y^2). 4. O novo Coeficiente de Variação (CV_y), comparando-o com o coeficiente de variação original (CV_x).

QUESTÃO 3: Interpretação de Histogramas e Interpolação de Frequências

Uma das tarefas mais importantes no ensino e na prática da Estatística Descritiva é a capacidade de ler e processar distribuições agregadas em tabelas de classes de frequência (frequências agrupadas), extraindo informações sem acesso aos dados brutos individuais.

Um grupo de 84 estudantes do Ensino Médio de Curitiba foi submetido a um teste padronizado de proficiência matemática. Os resultados das notas obtidas foram organizados na seguinte tabela de frequências por classes intervalares (fechadas à esquerda e abertas à direita, $a \vdash b$):

Classes de Notas	Frequência Absoluta (f_a)	Frequência Relativa (f_r)	Frequência Acumulada (F_a)
[0; 2)	14	0,167	14
[2; 4)	28	0,333	42
[4; 6)	27	0,321	69
[6; 8)	11	0,131	80
[8; 10]	4	0,048	84
Total	84	1,000	—

Itens a serem respondidos: a) Calcule a estimativa da **Média Aritmética** aproximada deste conjunto de dados agrupados, utilizando o ponto médio (y_i^*) como representante de cada classe intervalar. Apresente o desenvolvimento algébrico do cálculo da média ponderada.

b) O conselho de classe da escola estabeleceu que a nota mínima para aprovação e participação em projetos avançados de robótica do campus é 5,00. Como a nota 5,00 está localizada exatamente no meio do intervalo de classe [4; 6), responda:

- Sob a premissa de que os dados individuais estão distribuídos de maneira perfeitamente **uniforme (homogênea)** dentro de cada intervalo de classe, calcule a porcentagem exata de alunos aprovados nesta avaliação. Apresente o raciocínio de interpolação linear utilizado.

c) Esboce mentalmente o histograma de frequências absolutas para estas notas. Com base na relação visual entre as frequências das classes e no comportamento das caudas, classifique a **assimetria** aproximada da distribuição de notas em *simétrica*, *assimétrica positiva (à direita)* ou *assimétrica negativa (à esquerda)*. Justifique sua classificação sem calcular a mediana ou a moda.

QUESTÃO 4: Comparação Gráfica Multivariada via Box-Plots

Em Matemática Industrial, a análise exploratória bivariada para uma variável qualitativa e outra quantitativa é rotineiramente conduzida através da comparação visual de múltiplos diagramas de caixa (Box-Plots) dispostos lado a lado.

Considere um estudo que avaliou o tempo de execução (em segundos) de uma tarefa de simulação estocástica de tráfego aéreo sob três sistemas operacionais concorrentes (Sistemas A, B e C), com amostras de tamanho idêntico de simulações. A análise descritiva gerou o seguinte gráfico de box-plots comparativos:

- **Sistema A:** A caixa está localizada em uma faixa de valores baixos. A mediana está perfeitamente no centro da caixa. Não há pontos plotados além dos limites dos bigodes. O bigode superior tem comprimento idêntico ao bigode inferior.
- **Sistema B:** A caixa está em uma faixa intermediária de valores. A mediana está encostada na linha inferior da caixa (próxima ao primeiro quartil Q_1). Há um longo bigode na parte superior e dois pontos individuais marcados de forma isolada muito acima do limite do bigode superior.
- **Sistema C:** A caixa está localizada em uma faixa de valores elevados. A mediana está posicionada muito próxima do topo da caixa (próxima ao terceiro quartil Q_3). O bigode inferior é visivelmente mais longo do que o bigode superior. Não há pontos isolados além dos limites dos bigodes.

Itens a serem respondidos: a) Compare a **tendência central** (desempenho típico) do tempo de simulação entre os três sistemas operacionais, ordenando-os do mais rápido ao mais lento com base em suas medianas.

b) Analise a **variabilidade relativa** e o comportamento de dispersão dos tempos de processamento de cada sistema. Qual dos três sistemas apresenta o desempenho mais estável e previsível (menor variabilidade interna medida pela amplitude interquartílica)? Justifique sua resposta.

c) Descreva o comportamento da **assimetria** da distribuição dos tempos de simulação para cada um dos três sistemas operacionais (A , B e C), baseando-se na posição da mediana em relação aos quartis e no comprimento dos bigodes.

d) Discuta o significado estatístico dos pontos individuais representados além dos bigodes no **Sistema B**. Como esses pontos são definidos formalmente no algoritmo de construção do Box-plot utilizando a Amplitude Interquartílica (AIQ)?

QUESTÃO 5: Associação Qualitativa, Contingência

A análise bivariada qualitativa investiga a relação de dependência entre duas variáveis categóricas estruturadas em tabelas de dupla entrada (contingência).

Considere uma amostra de 120 estudantes de graduação que foram acompanhados durante o período de exames. Registrou-se se o aluno participou ativamente das monitorias presenciais da disciplina de Introdução à Estatística (Variável X : Monitoria — Sim ou Não) e se obteve aprovação direta na primeira avaliação (Variável Y : Aprovado — Sim ou Não). Os resultados conjunturais absolutos foram consolidados na tabela de contingência a seguir:

Participou da Monitoria (X) \ Aprovado (Y)	Aprovado (Sim)	Aprovado (Não)	Total Marginal
Sim	45	15	60
Não	15	45	60
Total Marginal	60	60	120

Itens a serem respondidos: a) Obtenha a tabela de frequências relativas condicionadas por linha (ou seja, a distribuição percentual do status de aprovação de acordo com a participação ou não na monitoria).

b) Determine a frequência relativa marginal de aprovação, denotada por $fr(Y = \text{Sim})$, e as frequências relativas de aprovação dado o status de participação na monitoria, ou seja, $fr(Y = \text{Sim} \mid X = \text{Sim})$ e $fr(Y = \text{Sim} \mid X = \text{Não})$.

QUESTÃO 6: Correlação, Causalidade e Ética na Análise de Dados

O entendimento de que associação estatística não implica necessariamente em relação biológica ou física de causa e efeito é uma das competências éticas mais críticas do cientista e do professor de matemática.

Um estudo bivariado quantitativo coletou dados anuais ao longo de 20 anos sobre duas variáveis em escala global:

- X : O número estimado de piratas ativos operando nos mares do mundo (em milhares).
- Y : A temperatura média global registrada na superfície terrestre (em graus Celsius).

Ao calcular o Coeficiente de Correlação Linear de Pearson entre estas duas variáveis quantitativas, os pesquisadores encontraram um valor de:

$$r_{xy} = -0,985$$

Itens a serem respondidos: a) Classifique a força e a direção da associação linear indicada por este valor de coeficiente de correlação ($r = -0,985$). Descreva textualmente como se comportam as variáveis conjuntamente de acordo com essa associação.

b) O fato de o coeficiente de correlação ser extremamente elevado em termos absolutos ($|r| \approx 0,99$) nos permite afirmar com certeza científica que a redução do número de piratas no mundo é a causa física direta do aquecimento global verificado nas últimas décadas? Justifique detalhadamente sua resposta, abordando os conceitos de **variáveis de confusão (terceira variável)**, **correlações espúrias** e a **ética na interpretação de relatórios descritivos**.

Bloco B: Gabarito Comentado e Resoluções

Esta seção destina-se ao uso exclusivo do docente como guia de correção e discussão metodológica em sala de aula, contendo as respostas ideais fundamentadas e os scripts em R correspondentes para cada seção.

Resolução da Questão 1 (Amostragem e Delineamento)

- a) **Crítica aos Cenários Amostrais:**
 - **Cenário I: Amostragem Intencional ou por Julgamento (Não-probabilística).** O processo não envolve seleção aleatória simples. O RH seleciona os funcionários baseando-se em seu próprio julgamento subjetivo.
 - * *Vício/Viés:* O RH tende a selecionar funcionários mais engajados, mais vocais, com melhor relacionamento interno ou de cargos hierárquicos mais altos, sob-representando funcionários descontentes, tímidos ou de áreas operacionais periféricas. Não há representatividade matemática, inviabilizando qualquer inferência probabilística para a empresa inteira.
 - **Cenário II: Amostragem por Conveniência (Não-probabilística).** Embora a barreira pareça “sistemática” por inspecionar todos os carros, o período escolhido (um sábado à tarde, das 14h às 14:30h) representa uma amostra de conveniência temporal.
 - * *Vício/Viés:* Carros que circulam no sábado à tarde têm um perfil de uso essencialmente recreativo ou comercial leve, diferindo drasticamente do perfil de tráfego de caminhões e carros utilitários pesados que circulam nos dias de semana (segunda a sexta) em horários de pico industrial. Além disso, anomalias climáticas ou tráfego atípico naquele horário específico enviesam totalmente a estimativa de emissão média de poluentes da rodovia como um todo.
- b) **Proposta de Amostragem Probabilística para o Cenário I:**
 - O plano ideal é a **Amostragem Estratificada Proporcional**.
 - *Passo a passo:*
 1. Dividir a população total de funcionários em estratos exclusivos de acordo com seus departamentos/áreas (ex: Engenharia, Vendas, Suporte, Administrativo).
 2. Determinar a proporção de funcionários que cada estrato representa em relação ao total da empresa ($W_h = N_h/N$).
 3. Para um tamanho de amostra desejado n , calcular a quota de cada departamento proporcionalmente ($n_h = n \times W_h$).
 4. Dentro de cada departamento, realizar um sorteio aleatório simples (AAS sem reposição) dos funcionários que responderão à pesquisa utilizando seus números de cadastro funcional.
- c) **Análise do Delineamento do Cenário III:**
 - Trata-se de um **Estudo Observacional**, apesar de haver a aplicação de métodos diferentes. O pesquisador não realizou uma alocação aleatória (*randomização*) dos alunos entre as turmas; ele utilizou grupos naturalmente pré-existentis (turmas do matutino e vespertino).
 - *Relação de Causalidade:* **Não é cientificamente válido estabelecer causalidade.** O efeito do método de ensino está completamente confundido com outras variáveis. Por exemplo:
 - * *Efeito Turno (Matutino vs. Vespertino):* Alunos do turno matutino podem estar mais descansados ou ter perfis socioeconômicos diferentes dos alunos do vespertino.
 - * *Efeito Professor/Turma:* A dinâmica interna, engajamento coletivo prévio e a composição da sala podem ditar as notas, independentemente da tecnologia interativa. Para provar causalidade, seria necessário um *experimento controlado*: sortear individualmente alunos de uma mesma população e distribuí-los aleatoriamente entre os dois métodos.
- d) **Classificação de Variáveis:**
 1. Número de viagens de ônibus: **Quantitativa Discreta**.
 2. Nível de satisfação (Likert): **Qualitativa Ordinal**.
 3. Identificação funcional: **Qualitativa Nominal** (o número funciona apenas como um rótulo identificador, não expressando quantidade ou ordem).
 4. Concentração de CO: **Quantitativa Contínua**.

Resolução da Questão 2 (Propriedades e Robustez)

- a) **Robustez e Outliers:**

- **Mediana:** Não sofrerá nenhuma alteração. A mediana é uma medida descritiva robusta (barreira de 50%). Como o erro ocorreu apenas na magnitude do maior valor (cauda superior extrema), a ordem de classificação dos dados e o elemento central da distribuição permanecem exatamente idênticos.
- **Média Aritmética:** Será fortemente deslocada para cima, uma vez que soma todos os valores individuais. Um único outlier extremo puxa o “centro de massa” para longe da concentração principal dos dados.
- **Medidas de Dispersão:** A **Amplitude Total** aumentará drasticamente de $21,5 - 11,5 = 10,0$ para $1100 - 11,5 = 1088,5$. O **Desvio Padrão** também inflará severamente por ser baseado nas diferenças quadráticas em relação à média.
- *Veredito:* A **Mediana** representa melhor a realidade do tempo típico de execução do algoritmo, pois não é distorcida por este ponto anômalo de falha de rede.

- b) **Demonstração das Propriedades de Transformação Linear:** Dada a transformação $y_i = ax_i + b$, onde $a = 4$ e $b = -20$:

1. **Nova Média ($\bar{y}$):**

$$\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i = \frac{1}{n} \sum_{i=1}^n (4x_i - 20) = 4 \left(\frac{1}{n} \sum_{i=1}^n x_i \right) - \frac{20n}{n} = 4\bar{x} - 20$$

$$\bar{y} = 4(80) - 20 = 320 - 20 = \mathbf{300 \text{ ms}}$$

2. **Novo Desvio Padrão (s_y):** O desvio padrão é afetado apenas pelo fator de escala $|a|$ (multiplicação), sendo imune a translações (soma/subtração de constantes):

$$s_y = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n [(4x_i - 20) - (4\bar{x} - 20)]^2}$$

$$s_y = \sqrt{\frac{1}{n-1} \sum_{i=1}^n [4(x_i - \bar{x})]^2} = 4 \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2} = 4s_x$$

$$s_y = 4(10) = \mathbf{40 \text{ ms}}$$

3. **Nova Variância (s_y^2):** A variância amostral escala com o quadrado do fator multiplicativo (a^2):

$$s_y^2 = (4)^2 s_x^2 = 16s_x^2 = 16 \times (10)^2 = 16 \times 100 = \mathbf{1600 \text{ ms}^2}$$

4. **Novo Coeficiente de Variação (CV_y):**

$$CV_x = \frac{s_x}{\bar{x}} = \frac{10}{80} = 0,125 \quad (12,50\%)$$

$$CV_y = \frac{s_y}{\bar{y}} = \frac{40}{300} \approx 0,1333 \quad (13,33\%)$$

Análise: O Coeficiente de Variação foi alterado. Como houve uma translação linear constante de subtração (-20), a média proporcionalmente reduziu mais do que a dispersão escalada, elevando ligeiramente a variabilidade relativa do novo conjunto de dados.

Resolução da Questão 3 (Tabelas e Interpolação)

- **a) Cálculo da Média Agrupada em Classes:** Primeiramente, determinamos os pontos médios (y_i^*) de cada intervalo de classe $[a; b)$ por $y_i^* = (a + b)/2$:
 - Classe 1: $y_1^* = (0 + 2)/2 = 1$
 - Classe 2: $y_2^* = (2 + 4)/2 = 3$
 - Classe 3: $y_3^* = (4 + 6)/2 = 5$
 - Classe 4: $y_4^* = (6 + 8)/2 = 7$
 - Classe 5: $y_5^* = (8 + 10)/2 = 9$

Agora, aplicamos a média aritmética ponderada pelas frequências absolutas ($f_{a,i}$):

$$\bar{y} = \frac{\sum_{i=1}^k f_{a,i} \cdot y_i^*}{n} = \frac{(14 \times 1) + (28 \times 3) + (27 \times 5) + (11 \times 7) + (4 \times 9)}{84}$$
$$\bar{y} = \frac{14 + 84 + 135 + 77 + 36}{84} = \frac{346}{84} \approx \mathbf{4,12 \text{ pontos}}$$

- **b) Interpolação Linear de Alunos Aprovados (Nota $\geq 5,00$):**
 - Queremos estimar o número de alunos com notas iguais ou superiores a 5,00.
 - Os alunos aprovados pertencem às classes intervalares $[4; 6)$, $[6; 8)$ e $[8; 10]$.
 - Para o intervalo $[4; 6)$, que possui 27 alunos, a nota de corte 5,00 divide a classe exatamente ao meio. Sob a hipótese de distribuição uniforme, metade desses alunos tiraram nota entre 4 e 5, e a outra metade tirou nota entre 5 e 6.
 - *Frequência estimada de aprovados na classe $[4; 6)$:* $27/2 = 13,5$ alunos.
 - *Soma total estimada de aprovados:*

$$\text{Aprovados} = 13,5 \text{ (da classe } [4; 6)) + 11 \text{ (da classe } [6; 8)) + 4 \text{ (da classe } [8; 10]) = 28,5 \text{ alunos}$$

- *Porcentagem estimada de aprovação:*

$$\% \text{ Aprovados} = \frac{28,5}{84} \times 100\% \approx \mathbf{33,93\%}$$

- **c) Forma da Distribuição (Assimetria):**
 - **Classificação:** A distribuição é **assimétrica positiva (à direita)**.
 - **Justificativa:** Observando as frequências absolutas, a grande concentração de dados ocorre nas classes iniciais inferiores (14 e 28 alunos nas notas de 0 a 4), acumulando a maior densidade à esquerda. À medida que a nota aumenta, as frequências diminuem de forma progressiva (11 e 4 alunos nas notas de 6 a 10), caracterizando uma cauda longa que se estende em direção aos valores mais elevados (à direita).

Resolução da Questão 4 (Comparação de Box-Plots)

- **a) Comparação de Tendência Central (Desempenho de Velocidade):**
 - A mediana é representada graficamente pela linha horizontal contida no interior da caixa de cada Box-plot.
 - Como o Sistema A possui a mediana na faixa mais baixa de tempos, ele é o sistema típico mais rápido. O Sistema B apresenta a mediana na faixa intermediária e o Sistema C na faixa de tempos elevados.
 - *Ordenação do mais rápido ao mais lento (em termos típicos):* **Sistema A < Sistema B < Sistema C.**
- **b) Análise da Estabilidade e Dispersão:**
 - A dispersão central dos dados é representada graficamente pela altura da caixa do Box-plot, que corresponde à Amplitude Interquartilica ($AIQ = Q3 - Q1$).

- O **Sistema A** apresenta o desempenho mais estável e homogêneo, pois a sua caixa é a mais estreita verticalmente (menor AIQ), indicando menor variabilidade nos tempos de processamento do algoritmo.
- c) **Avaliação de Assimetria Teórica:**
 - **Sistema A:** É **simétrico**. A linha da mediana está centralizada no meio da caixa, e os bigodes têm comprimentos idênticos.
 - **Sistema B:** É **assimétrico positivo (à direita)**. A linha da mediana está deslocada para a base da caixa (próxima a $Q1$), e o bigode superior é muito mais longo do que o inferior, indicando que a cauda superior de dados é alongada.
 - **Sistema C:** É **assimétrico negativo (à esquerda)**. A linha da mediana está deslocada para o topo da caixa (próxima a $Q3$), e o bigode inferior é visivelmente mais longo do que o superior, indicando cauda alongada à esquerda.
- d) **Significado Estatístico dos Outliers (Sistema B):**
 - Os pontos individuais isolados na extremidade representam **valores atípicos (outliers)** de tempos de execução.
 - *Definição formal:* O Box-plot calcula limites de corte baseados em $1,5 \times AIQ$. Qualquer observação y_i que esteja além desses limites é plotada como um ponto isolado:

$$\text{Limite Superior (LS)} = Q3 + 1,5 \times (Q3 - Q1)$$

Os dois pontos individuais observados no Sistema B representam execuções de simulação que demoraram um tempo excepcionalmente alto, ultrapassando o valor crítico de LS .

Resolução da Questão 5 (Contingência)

- a) **Tabela de Frequências Relativas Condicionais (Por Linha):** Dividimos cada frequência absoluta conjunta pelo respectivo total marginal da linha:
 - *Para quem fez Monitoria (Sim):*
 - * Aprovado (Sim): $45/60 = 0,7500$ (75,00%)
 - * Aprovado (Não): $15/60 = 0,2500$ (25,00%)
 - *Para quem NÃO fez Monitoria (Não):*
 - * Aprovado (Sim): $15/60 = 0,2500$ (25,00%)
 - * Aprovado (Não): $45/60 = 0,7500$ (75,00%)

Monitoria (X) \ Aprovado (Y)	Aprovado (Sim)		Aprovado (Não)		Total Marginal	
Sim	0,75	(75%)	0,25	(25%)	1,00	(100%)
Não	0,25	(25%)	0,75	(75%)	1,00	(100%)

- b) **Frequências relativas marginais e Condicionais:**
 - Frequência relativa marginal de aprovação: $fr(Y = \text{Sim}) = 60/120 = 0,5000$ (50,00%).
 - Frequência relativa condicional de aprovação dado que fez monitoria: $fr(Y = \text{Sim} \mid X = \text{Sim}) = 0,7500$ (75,00%).
 - Frequência relativa condicional de aprovação dado que não fez monitoria: $fr(Y = \text{Sim} \mid X = \text{Não}) = 0,2500$ (25,00%).

Resolução da Questão 6 (Correlação e Causalidade)

- a) **Interpretação do Coeficiente de Correlação:**
 - O valor $r = -0,985$ indica uma **associação linear negativa extremamente forte** (quase perfeita).

- *Comportamento conjunto*: À medida que a variável X (número de piratas) diminui ao longo dos anos, a variável Y (temperatura média global) aumenta de forma quase perfeitamente linear e sincronizada.
- b) **Discussão Científica e Ética sobre Causalidade**:
 - **De forma alguma isso indica causalidade**. Correlação linear mede unicamente a força e a direção da associação matemática simultânea entre dois eixos numéricos, não estabelecendo nexos físicos de causa e efeito.
 - *Variáveis de Confusão / Terceira Variável*: Ambas as variáveis são influenciadas pela **passagem do tempo e pelo desenvolvimento industrial moderno**. O avanço tecnológico e o aumento da fiscalização marítima reduziram drasticamente a pirataria clássica, enquanto a atividade industrial humana intensa e a queima de combustíveis fósseis podem ter elevado a emissão de gases de efeito estufa. O tempo atua como uma variável de confusão oculta.
 - *Ética na Estatística*: O analista deve evitar tirar conclusões precipitadas de correlações espúrias. Divulgar dados correlacionados insinuando nexos causais sem fundamentação física ou delineamento experimental controlado é uma conduta antiética grave que induz ao erro, violando a integridade da análise científica.

Implementação Prática e Simulações no R

Abaixo encontra-se o script computacional completo em linguagem R para demonstrar aos estudantes as validações computacionais de cada questão:

```
# --- SCRIPT DE APOIO DOCENTE - REVISÃO EXPLORATÓRIA ---

# --- Questão 2: Propriedades de Transformações Lineares ---
# Vetor hipotético de tempos originais (média 80, sd 10)
x <- c(68, 72, 75, 75, 78, 82, 85, 85, 88, 102)
mean(x)
sd(x)

# Transformação linear  $y = 4x - 20$ 
y <- 4 * x - 20
cat("Nova Média (R):", mean(y), "\n")
cat("Novo Desvio Padrão (R):", sd(y), "\n")
cat("Nova Variância (R):", var(y), "\n")

# --- Questão 3: Interpolação de Notas do Histograma ---
# Simulação dos 84 alunos respeitando a tabela de frequências
notas <- c(runif(14, 0, 2), runif(28, 2, 4), runif(27, 4, 6), runif(11, 6, 8), runif(4, 8, 10))

# Histograma empírico para visualização
hist(notas, breaks = c(0,2,4,6,8,10), right = FALSE,
     col = "lightblue", main = "Distribuição de Notas dos Alunos",
     xlab = "Notas", ylab = "Frequência Absoluta")

# --- Questão 5: Tabela de Contingência e Independência ---
# Criando a matriz de dados
tabela <- matrix(c(45, 15, 15, 45), nrow = 2, byrow = TRUE)
rownames(tabela) <- c("Monitoria: Sim", "Monitoria: Não")
colnames(tabela) <- c("Aprovado: Sim", "Aprovado: Não")
```

```

# Frequências relativas marginais e condicionais
print("Frequências Absolutas Conjuntas:")
print(tabela)

print("Proporções Condicionais por Linha:")
print(prop.table(tabela, margin = 1))

# --- Questão 6: Associação Espúria (Piratas vs Temperatura) ---
piratas <- c(35, 20, 15, 10, 5, 1) # decrescente
temperatura <- c(14.2, 14.5, 14.8, 15.1, 15.3, 15.6) # crescente

# Coeficiente de correlação de Pearson
r <- cor(piratas, temperatura)
cat("Coeficiente r calculado:", round(r, 4), "\n")

# Gráfico de Dispersão com Linha de Tendência
plot(piratas, temperatura, col = "red", pch = 16,
     main = "Correlação Espúria: Piratas vs Temperatura",
     xlab = "Quantidade de Piratas (Milhares)", ylab = "Temperatura Média (°C)")
abline(lm(temperatura ~ piratas), col = "blue", lwd = 2)

```