

# Análise exploratória

Resumos numéricos - medidas de posição

Prof. Me. Lineu Alberto Cavazani de Freitas

Departamento de Estatística  
Laboratório de Estatística e Geoinformação




# Análise exploratória

- ▶ Parte primordial de qualquer análise estatística é chamada **análise descritiva** ou **exploratória**.
- ▶ Consiste basicamente de **tabelas**, **resumos numéricos** e **análises gráficas** das variáveis disponíveis em um conjunto de dados.
- ▶ Trata-se de uma etapa de extrema importância e deve preceder qualquer análise mais sofisticada.
- ▶ As técnicas de análise exploratória visam **resumir** e **apresentar** as informações de um conjunto de dados brutos.

## Análise exploratória

- ▶ A análise exploratória de dados é uma área relativamente nova.
- ▶ Nasceu do clássico livro **Exploratory Data Analysis** de **John Tukey** em 1977.
- ▶ Algo curioso é que Tukey tinha uma relação próxima com a Ciência da Computação e definiu os termos **bit** e **software**.



**Figura 1.** Capa do livro *Exploratory Data Analysis* de John Tukey.

# Análise exploratória

- ▶ Como quase tudo em análise de dados, o **avanço computacional** permitiu com que a análise exploratória evoluísse substancialmente.
- ▶ Por exemplo: historicamente o processo de criação de um gráfico era reservado a pessoas qualificadas pois a produção de uma visualização era difícil.
- ▶ Hoje qualquer pessoa pode inserir dados em um aplicativo e gerar um gráfico.
- ▶ Este tipo de facilidade é importante para disseminação e democratização dos métodos, porém abre margem para certas práticas inadequadas.

# Análise exploratória

- ▶ Tentar compreender um conjunto de dados sem algum método que permita resumir as informações é inviável.
- ▶ A análise exploratória é a primeira forma de tentarmos entender o que acontece nos nossos dados.
- ▶ Uma das tarefas é a etapa de consistência dos dados, isto é, verificar se os dados coletados são condizentes com a realidade.



Figura 2. Extraído de pixabay.com.

# Análise exploratória

- ▶ O conjunto de técnicas aplicáveis está diretamente associado ao **tipo das variáveis de interesse** (quantitativas x qualitativas) e suas ramificações.
- ▶ Podemos conduzir análises focadas nas variáveis uma a uma (**análises univariadas**).
- ▶ Também podemos conduzir análises focadas em avaliar a relação entre as variáveis (**análises multivariadas**).



Figura 3. Extraído de pixabay.com.

# Análise exploratória

Podemos fazer uso diversas técnicas, tais como

- ▶ Tabelas de frequência absolutas.
- ▶ Tabelas de frequência relativas.
- ▶ Tabelas de frequência acumuladas.
- ▶ Tabelas para múltiplas variáveis.
- ▶ Gráficos.
- ▶ Medidas de posição central.
- ▶ Medidas de posição relativa.
- ▶ Medidas de forma.
- ▶ Medidas de dispersão.
- ▶ Medidas de associação.



# Resumos numéricos

# Resumos numéricos

- ▶ Uma forma de resumir a informação contida em um conjunto de dados é por meio dos **resumos numéricos**.
- ▶ Resumos numéricos são basicamente **números que resumem números**.
- ▶ Os dois principais grupos são as medidas de **posição** (central e relativa) e **dispersão**.
- ▶ Existem outros conjuntos de medidas, como as medidas de **forma** e também as de **relação/associação**.



# Medidas de posição central

# Medidas de posição central

- ▶ Um passo fundamental na exploração dos dados é definir um **valor típico** (uma estimativa onde a maior parte dos dados está localizada).
- ▶ Considerando um conjunto de valores qualquer, como definir um valor central? A resposta é: depende do critério.
- ▶ As medidas de posição central buscam expressar o **centro** de uma variável por meio de ideias como:
  - ▶ Centro de massa.
  - ▶ Valor que divide a amostra em partes iguais.
  - ▶ Valores de maior frequência ou densidade.
- ▶ Algumas possibilidades são
  - ▶ Média.
  - ▶ Mediana.
  - ▶ Moda.
  - ▶ Média geométrica.
  - ▶ Média harmônica.
  - ▶ Média aparada.

# Média aritmética

- ▶ Soma de todos os valores dividida pela quantidade de elementos.
- ▶ Interpretação física de centro de gravidade.
- ▶ Medida influenciada por valores extremos.

## Expressão

Sejam  $y_1, y_2, \dots, y_n$  os  $n$  valores de uma variável  $Y$ , a média é dada por:

$$\bar{y} = \frac{y_1 + y_2 + \dots + y_n}{n} = \frac{\sum_{i=1}^n y_i}{n}.$$

# Média aritmética

## Exemplo

- ▶ Considere que uma turma possui 10 alunos.
- ▶ Estes alunos realizaram uma avaliação.
- ▶ Considere que as notas obtidas foram:

60; 65; 77; 95; 56; 94; 97; 81; 80; 48

- ▶ Qual foi a nota média da turma?

Y : Notas obtidas.

$$\bar{y} = \frac{60 + 65 + 77 + 95 + 56 + 94 + 97 + 81 + 80 + 48}{10} = \frac{753}{10} = 75,3$$

# Média aritmética ponderada

- ▶ Indicada para **dados agrupados** em tabelas de frequência ou situações em que existe motivo para unidades receberem um **peso** maior.
- ▶ Obtêm-se os produtos entre frequências absolutas (ou pesos) e os valores que a variável assume.
- ▶ Somam-se os produtos e divide-se pela soma das frequências (quantidade de elementos).
- ▶ No caso de faixas de valores, usa-se o centro da faixa.

$$\bar{y} = \frac{\sum_{i=1}^k f_i \cdot y_i}{\sum_{i=1}^k f_i}.$$

- ▶  $f_i$  representa a frequência da classe  $i$ .
- ▶  $k$  representa o número de classes ( $k \leq n$ ).

# Média aritmética ponderada

## Exemplo 1

- ▶ Considere que uma prova com 10 questões de múltipla escolha foi aplicada em uma turma com 100 alunos.
- ▶ Só temos acesso à uma tabela de frequências do número de questões corretas.
- ▶ Qual é o número médio de questões corretas?

**Tabela 1.** Tabela de frequências do número de questões acertadas.

|            |   |   |   |   |   |    |    |    |   |   |    |
|------------|---|---|---|---|---|----|----|----|---|---|----|
| Acertos    | 0 | 1 | 2 | 3 | 4 | 5  | 6  | 7  | 8 | 9 | 10 |
| Frequência | 1 | 0 | 0 | 5 | 2 | 30 | 21 | 29 | 8 | 3 | 1  |

# Média aritmética ponderada

## Exemplo 1

Y : Número de acertos.

$$\bar{y} = \frac{(0 \times 1) + (1 \times 0) + (2 \times 0) + (3 \times 5) + \dots + (7 \times 29) + (8 \times 8) + (9 \times 3) + (10 \times 1)}{100}$$

$$\bar{y} = \frac{0 + 0 + 0 + 15 + 8 + 150 + 126 + 203 + 64 + 27 + 10}{100} = 6,03$$

# Média aritmética ponderada

## Exemplo 2

- ▶ Considere a seguinte tabela de frequências da idade dos funcionários de uma empresa.
- ▶ Qual é a idade média dos funcionários?

Tabela 2. Tabela de frequências das idades dos funcionários.

|            |         |         |         |         |         |         |         |         |         |         |
|------------|---------|---------|---------|---------|---------|---------|---------|---------|---------|---------|
| Faixas     | [20,25] | (25,30] | (30,35] | (35,40] | (40,45] | (45,50] | (50,55] | (55,60] | (60,65] | (65,70] |
| Frequência | 3       | 45      | 191     | 310     | 248     | 140     | 54      | 7       | 0       | 2       |

# Média aritmética ponderada

## Exemplo 2

Y : Idade do funcionário.

$$\bar{y} = \frac{(22,5 \times 3) + (27,5 \times 45) + (32,5 \times 191) \dots + (57,5 \times 7) + (62,5 \times 0) + (67,5 \times 2)}{1000}$$

$$\bar{y} = \frac{67,5 + 1237,5 + 6207,5 + 11625 + \dots + 2835 + 402,5 + 0 + 135}{1000} = 39,7$$

# Outros tipos de média

- ▶ Média aritmética e ponderada são os tipos de média mais comuns.
- ▶ Contudo existem outras possibilidades como
  - ▶ Média geométrica.
  - ▶ Média harmônica.
  - ▶ Média aparada.

# Mediana

- ▶ Valor que ocupa a **posição intermediária** dos valores ordenados.
- ▶ Divide o vetor de valores em 2 partes de mesmo tamanho.
- ▶ Metade dos valores é menor que a mediana e a outra metade maior que a mediana.
- ▶ Existem diferentes métodos para se obter a mediana, um deles é o chamado **método de Tukey**.
- ▶ No método de Tukey basta **ordenar o conjunto de valores** e verificar qual é o valor central.
- ▶ Se o número de observações for ímpar, a mediana é o valor central.
- ▶ Se o número de observações for par, a mediana é a média dos dois valores centrais.

# Mediana (pelo método de Tukey)

- ▶ Passo 1: ordenar.

$$y_{(1)} \leq y_{(2)} \leq \cdots \leq y_{(n-1)} \leq y_{(n)}.$$

- ▶ Passo 2: obter a mediana de acordo com o número de elementos.

$$md = \begin{cases} y_{((n+1)/2)}, & \text{se } n \text{ for ímpar.} \\ (y_{(n/2)} + y_{(n/2+1)})/2, & \text{se } n \text{ for par.} \end{cases}$$

# Mediana (pelo método de Tukey)

## Exemplo

- ▶ Uma concessionária está fazendo o levantamento anual de vendas.
- ▶ Considere que as vendas por mês do ano anterior estão dadas na tabela.
- ▶ Qual é o número mediano de vendas?

Tabela 3. Tabela de frequências das vendas mensais.

| Mês    | Jan | Fev | Mar | Abr | Mai | Jun | Jul | Ago | Set | Out | Nov | Dez |
|--------|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|
| Vendas | 93  | 113 | 112 | 104 | 84  | 104 | 107 | 105 | 96  | 92  | 93  | 97  |

# Mediana (pelo método de Tukey)

## Exemplo

- ▶ Passo 1: ordenar os valores.

Tabela 4. Vendas ordenadas.

|        |    |    |    |    |    |    |     |     |     |     |     |     |
|--------|----|----|----|----|----|----|-----|-----|-----|-----|-----|-----|
| (i)    | 1  | 2  | 3  | 4  | 5  | 6  | 7   | 8   | 9   | 10  | 11  | 12  |
| Vendas | 84 | 92 | 93 | 93 | 96 | 97 | 104 | 104 | 105 | 107 | 112 | 113 |

- ▶ Passo 2: obter a mediana de acordo com o número de elementos.
  - ▶ O número de elementos é par, portanto a mediana será a média dos dois valores centrais.
  - ▶ Mediana:  $(97 + 104)/2 = 100,5$

## Exemplo

- ▶ Valor ou classe que apresenta **maior frequência ou densidade**.
  - ▶ Valor mais **típico**, aquele que mais se repete.
  - ▶ Quando todos os valores são distintos, não existe moda.
  - ▶ Quando a maior frequência está associada a mais de um valor, existe mais de uma moda.
- ▶ Considere que os valores a seguir dizem respeito ao número de filhos por pessoa em um grupo.

2; 3; 6; 1; 3;  
4; 1; 2; 0; 1;  
1; 0; 1; 4; 1
  - ▶ Qual é a moda?
    - ▶ O valor mais frequente é 1, que aparece 6 vezes.

# Média, mediana e moda

- ▶ Na prática, estas medidas possuem **vantagens** e **desvantagens**.
- ▶ Caso haja **valores discrepantes** a **média** é uma medida **altamente influenciada**, o que não acontece com a moda e a mediana.
- ▶ Já a **mediana** é difícil de ser obtida quando existem muitos dados, dado que o **processo de ordenação é custoso**.
- ▶ A dificuldade com a **moda** surge quando trabalha-se com **distribuições multimodais**, isto é diversos valores tem a mesma frequência de ocorrência.

# Média, mediana e moda

- ▶ A **média** tende a ser uma boa alternativa quando a distribuição é **unimodal, simétrica e sem valores extremos**.
- ▶ A **mediana** tende a ser uma boa alternativa para **distribuições assimétricas** ou com presença de **valores extremos**.
- ▶ A **moda** tende a ser uma boa alternativa quando **valores se repetem**, estão **agrupados em classes** ou trata-se de uma **variável qualitativa**.
- ▶ Média, moda e mediana aproximam-se em distribuições **unimodais simétricas**.

# Média, mediana, moda e assimetria

- ▶ Vimos anteriormente como avaliar assimetria por meio de recursos gráficos.
- ▶ Podemos utilizar as medidas de posição central
  - ▶ **Assimetria à direita:**  $\text{moda} < \text{mediana} < \text{média}$ .
  - ▶ **Assimetria à esquerda:**  $\text{média} < \text{mediana} < \text{moda}$ .
  - ▶ **Simetria:**  $\text{média} = \text{mediana} = \text{moda}$ .




Figura 4. Relação medidas descritivas e assimetria



# Medidas de posição relativa

# Medidas de posição relativa

- ▶ As medidas de posição relativa ou separatrizes buscam representar **pontos do domínio** em que a variável apresenta porções com frequências conhecidas.
- ▶ Visam encontrar valores que representam alguma parcela dos dados.
- ▶ Algumas possibilidades são
  - ▶ Quartis.
  - ▶ Decis.
  - ▶ Percentis.
  - ▶ Máximo.
  - ▶ Mínimo.

# Quartis

- ▶ Dividem a amostra em 4 **partes de mesmo tamanho**.
- ▶ A ideia para obtenção é similar à da **mediana**.
- ▶ Na verdade, a mediana é um dos quartis: o segundo.
- ▶ O primeiro e terceiro quartil são as **medianas** das duas partes divididas pela mediana (método de Tukey).

# Quartis

- ▶ O **primeiro quartil** ( $Q_1$ ) é o valor que marca  $1/4$  das observações, isto é, 25%.
- ▶ O **segundo quartil** ( $Q_2$ ) é o valor que marca  $2/4 = 1/2$  das observações, isto é, 50% (a mediana).
- ▶ O **terceiro quartil** ( $Q_3$ ) é o valor que marca  $3/4$  das observações, isto é, 75%.
- ▶ A diferença entre primeiro e terceiro quartil é chamada de **amplitude interquartílica** ( $AIQ = Q_3 - Q_1$ ).
- ▶ Estas quantidades são usadas para criação de um poderoso gráfico: o **box-plot**.

# Quartis

## Exemplo

- Considere os seguintes valores:

6; 12; 14; 7; 11; 7; 6; 12; 4; 11; 3; 4; 3; 4; 2

- Obtenha os quartis e a amplitude interquartílica.
- Passo 1: **ordenar**.

Tabela 5. Valores ordenados.

|         |   |   |   |   |   |   |   |   |   |    |    |    |    |    |    |
|---------|---|---|---|---|---|---|---|---|---|----|----|----|----|----|----|
| Posição | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 | 11 | 12 | 13 | 14 | 15 |
| Valor   | 2 | 3 | 3 | 4 | 4 | 4 | 6 | 6 | 7 | 7  | 11 | 11 | 12 | 12 | 14 |

# Quartis

## Exemplo

- ▶ Passo 2: **obter o segundo quartil (mediana).**
  - ▶ Número de elementos: 15.
  - ▶ Posição do segundo quartil: 8.
  - ▶ Valor do segundo quartil: 6.
- ▶ Passo 3: **obter a mediana dos valores da primeira parcela.**
  - ▶ Número de elementos: 8 (da posição 1 até 8).
  - ▶ Posição da mediana da primeira parcela: 4,5.
  - ▶ Valor do segundo quartil:  $(4 + 4)/2 = 4$ .
- ▶ Passo 4: **obter a mediana dos valores da segunda parcela.**
  - ▶ Número de elementos: 8 (da posição 8 até 15).
  - ▶ Posição da mediana da segunda parcela: 4,5.
  - ▶ Valor do segundo quartil:  $(11 + 11)/2 = 11$ .
- ▶  $Q_1 = 4$ ,  $Q_2 = 6$ ,  $Q_3 = 11$ .
- ▶ Amplitude interquartílica.

$$AIQ = Q_3 - Q_1 = 11 - 4 = 7$$

# Quartis e o Box-plot

- ▶ O box-plot faz uso dos **quartis** para obtenção de um **gráfico**.
- ▶ Com ele é possível analisar a distribuição dos dados: **posição, variabilidade, assimetria, valores atípicos** (outliers).




Figura 5. Ilustração box-plot completo.

## Quartis e o Box-plot

- ▶ O Box-plot é construído a partir de **5 pontos** que resumem a distribuição dos dados observados: o **limite inferior**, o **1º quartil**, a **mediana**, o **3º quartil** e o **limite superior**.
- ▶ Os **limites inferior** e **superior** são utilizados para detectar observações que estão longe da massa central localizada entre o primeiro e o terceiro quartis.
- ▶ Entre o primeiro e terceiro quartil está a **mediana**. Não necessariamente a mediana estará no centro da caixa.




Figura 6. Ilustração box-plot completo.

# Quartis e o Box-plot

- A construção de um box-plot inicia-se com um retângulo em que a aresta inferior coincide com o **primeiro quartil** e a superior com o **terceiro quartil**.




Figura 7. Arestas de um box-plot.

# Quartis e o Box-plot

- ▶ A **mediana** é representada por um traço entre as duas arestas.
- ▶ De  $Q_1$  até  $Q_3$  estão 50% das observações centrais, o que dá uma ideia a respeito de quão dispersos são os valores.




Figura 8. Arestas e mediana em um box-plot.

# Quartis e o Box-plot

- ▶ Para obtenção da **amplitude do box-plot** além do retângulo faz-se  $[Q1 - 1,5AIQ; Q3 + 1,5AIQ]$ .
- ▶ Desenha-se então uma linha até estes valores.
  - ▶ Se estes valores excedem o mínimo e o máximo da variável, então a linha para no mínimo e no máximo da variável.




Figura 9. Inclusão dos limites de um box-plot.

# Quartis e o Box-plot

- Valores além destes extremos são marcados como um ponto ou asterisco e são os candidatos a **valores atípicos**.




Figura 10. Box-plot completo.

# Quartis e o Box-plot

- ▶ Os limitantes inferior e superior de um box-plot também são conhecidos como **valores adjacentes** ou também como **mínimo e máximo típicos**.
- ▶ Existem outras formas de obtenção de um box-plot, como por exemplo o box-plot em que não são calculados o mínimo e máximo típicos.
- ▶ Podem-se usar também outros quantis e outros pontos de corte, ou seja, existem outras formas para detectar pontos distantes da massa de dados.
- ▶ A interpretação do gráfico vai depender de como ele foi construído.
- ▶ Quanto mais observações, mais confiável será o box-plot.
- ▶ Contudo, quanto mais observações é natural que surjam mais pontos além dos limites do gráfico.

# Quartis e o Box-plot

- ▶ Os pontos fora dos limites do box-plot costumam ser chamados de **valores atípicos ou outliers**.
- ▶ A definição exata de outlier é bastante **subjetiva** e vai além dos box-plots.
- ▶ Qualquer valor que seja muito distante dos outros valores em um conjunto de dados pode ser considerado outlier. Podemos usar o z-escore para verificar quais são os candidatos a outliers.
- ▶ Ser um outlier não torna um valor inválido ou errado, mas é um indicativo de um comportamento atípico (que pode ser causado por um erro de medida por exemplo).

# Quartis para dados agrupados

Para calcular os quartis quando os dados estão agrupados, considere:

- ▶  $n$  é o número total de observações;
- ▶  $Q_i (i = 1, 2, 3)$  é o quartil que desejamos obter;
- ▶  $(i \cdot n/4)$  é a posição na qual se encontra o quartil  $Q_i$ ;
- ▶  $l$  é o limite inferior da classe que contem  $Q_i$ ;
- ▶  $f$  é a frequência na classe que contem  $Q_i$ ;
- ▶  $h$  é a amplitude na classe que contem  $Q_i$ ;
- ▶  $F_{ant}$  é a frequência acumulada até a classe anterior à que contem  $Q_i$ .

O quartil  $Q_i$  é obtido aplicando-se a seguinte fórmula:

$$Q_i = l + \frac{(i \cdot n/4 - F_{ant})}{f} \cdot h$$

# Outras medidas

- ▶ O **mínimo** e o **máximo** também são medidas de posição relativa e fornecem informação quanto ao domínio da variável.
- ▶ **Quartis** são a forma mais famosa de particionamento dos dados, porém qualquer outro percentual pode ser obtido.
- ▶ Se temos um conjunto de  $n$  valores, organizados de forma crescente, o  $P$ -ésimo percentil é um número tal que  $P\%$  dos valores estejam à sua esquerda e  $(100 - P)\%$  à sua direita.
- ▶ Por exemplo, se obtivermos os valores que separam a amostra em 10 partes com frequência  $1/10$ , temos os decis.
- ▶ Estas **separatrizes** podem ser obtidas por meio do **gráfico de frequências acumuladas**.



## O que foi visto:

- ▶ Resumos numéricos.
- ▶ Medidas de posição central.
- ▶ Medidas de posição relativa.

## Próximos assuntos:

- ▶ Medidas de dispersão.