

# Análise exploratória

Resumos numéricos - medidas de dispersão

Prof. Me. Lineu Alberto Cavazani de Freitas

Departamento de Estatística  
Laboratório de Estatística e Geoinformação



# Análise exploratória

- ▶ Parte primordial de qualquer análise estatística é chamada **análise descritiva** ou **exploratória**.
- ▶ Consiste basicamente de **tabelas**, **resumos numéricos** e **análises gráficas** das variáveis disponíveis em um conjunto de dados.
- ▶ Trata-se de uma etapa de extrema importância e deve preceder qualquer análise mais sofisticada.
- ▶ As técnicas de análise exploratória visam **resumir** e **apresentar** as informações de um conjunto de dados brutos.

# Análise exploratória

- ▶ A análise exploratória de dados é uma área relativamente nova.
- ▶ Nasceu do clássico livro **Exploratory Data Analysis** de **John Tukey** em 1977.
- ▶ Algo curioso é que Tukey tinha uma relação próxima com a Ciência da Computação e definiu os termos **bit** e **software**.




Figura 1. Capa do livro Exploratory Data Analysis de John Tukey.

# Análise exploratória

- ▶ Como quase tudo em análise de dados, o **avanço computacional** permitiu com que a análise exploratória evoluísse substancialmente.
- ▶ Por exemplo: historicamente o processo de criação de um gráfico era reservado a pessoas qualificadas pois a produção de uma visualização era difícil.
- ▶ Hoje qualquer pessoa pode inserir dados em um aplicativo e gerar um gráfico.
- ▶ Este tipo de facilidade é importante para disseminação e democratização dos métodos, porém abre margem para certas práticas inadequadas.

# Análise exploratória

- ▶ Tentar compreender um conjunto de dados sem algum método que permita resumir as informações é inviável.
- ▶ A análise exploratória é a primeira forma de tentarmos entender o que acontece nos nossos dados.
- ▶ Uma das tarefas é a etapa de consistência dos dados, isto é, verificar se os dados coletados são condizentes com a realidade.



Figura 2. Extraído de pixabay.com.

# Análise exploratória

- ▶ O conjunto de técnicas aplicáveis está diretamente associado ao **tipo das variáveis de interesse** (quantitativas x qualitativas) e suas ramificações.
- ▶ Podemos conduzir análises focadas nas variáveis uma a uma (**análises univariadas**).
- ▶ Também podemos conduzir análises focadas em avaliar a relação entre as variáveis (**análises multivariadas**).



Figura 3. Extraído de pixabay.com.

# Análise exploratória

Podemos fazer uso diversas técnicas, tais como

- ▶ Tabelas de frequência absolutas.
- ▶ Tabelas de frequência relativas.
- ▶ Tabelas de frequência acumuladas.
- ▶ Tabelas para múltiplas variáveis.
- ▶ Gráficos.
- ▶ Medidas de posição central.
- ▶ Medidas de posição relativa.
- ▶ Medidas de forma.
- ▶ Medidas de dispersão.
- ▶ Medidas de associação.



# Resumos numéricos

# Resumos numéricos

- ▶ Uma forma de resumir a informação contida em um conjunto de dados é por meio dos **resumos numéricos**.
- ▶ Resumos numéricos são basicamente **números que resumem números**.
- ▶ Os dois principais grupos são as medidas de **posição** (central e relativa) e **dispersão**.
- ▶ Existem outros conjuntos de medidas, como as medidas de **forma** e também as de **relação/associação**.



# Medidas de dispersão

# Medidas de dispersão

- ▶ Em geral usamos uma **medida de posição central**, que nos dá uma ideia de centro dos dados.
- ▶ Mas conjuntos de dados com **diferentes valores podem gerar as mesmas medidas de posição**.
- ▶ E mesmo com medidas de posição idênticas, um pode ser **mais disperso** que o outro.
- ▶ Portanto **complementamos a informação** a respeito do centro **com uma medida de dispersão**, que nos dá uma noção de quão dispersos são os dados.

# Medidas de dispersão

Considere os seguintes conjuntos de valores:

|   |   |   |   |   |   |    |    |   |   |   |
|---|---|---|---|---|---|----|----|---|---|---|
| A | 5 | 5 | 5 | 5 | 5 | 5  | 5  | 5 | 5 | 5 |
| B | 5 | 4 | 4 | 5 | 6 | 5  | 4  | 6 | 5 | 6 |
| C | 0 | 5 | 9 | 0 | 5 | 11 | 10 | 5 | 5 | 0 |

- ▶ Os conjuntos apresentam valores distintos, mas as medidas de posição central (média, moda e mediana), são idênticas.
- ▶ Precisamos de formas de mensurar o quanto os valores variam.

# Medidas de dispersão

- ▶ As medidas de dispersão são utilizadas para expressar informações como o **domínio** da variável, grau de **dispersão** ao redor do centro (**variabilidade**), e também **distanciamento** dos valores com relação ao centro.
- ▶ Estas medidas buscam mensurar o quanto os dados estão “compactados” ou “espalhados”.
- ▶ Uma medida de dispersão **não pode ser negativa**: ela será zero, indicando que todos os dados são iguais, ou ela é positiva, indicando algum grau de variabilidade nos dados.

# Medidas de dispersão

- ▶ As medidas de dispersão mais usadas são baseadas nas diferenças entre cada observação e uma medida de posição central, esta diferença é chamada de **desvio**.
- ▶ Um jeito de medir a variabilidade como um todo é encontrar um **valor típico para os desvios**, como uma média.
- ▶ Fazer isso com os desvios simples não é muito inteligente. Desvios negativos se anulam com os positivos e a soma dos desvios com relação a média sempre será 0.
- ▶ Uma alternativa é calcular a média dos **desvios absolutos ou quadráticos** com relação a alguma medida de posição central.

# Medidas de dispersão

- ▶ Algumas medidas possíveis são
  - ▶ Amplitude.
  - ▶ Desvio absoluto médio ou mediano.
  - ▶ Variância.
  - ▶ Desvio padrão.
  - ▶ Coeficiente de variação.
  - ▶ z-escore.

# Amplitude

- ▶ Diferença entre o **maior** e o **menor** valor da variável.
- ▶ Sensível a valores extremos.
- ▶ Usa apenas duas medidas.

$$Amp = \max(y) - \min(y) = y(n) - y(1)$$

# Amplitude

## Exemplo

- ▶ Retomando o problema das notas de 10 alunos, em que as notas obtidas foram:

60; 65; 77; 95; 56; 94; 97; 81; 80; 48

Y : Notas obtidas.

$$Amp = 97 - 48 = 49$$

# Desvio absoluto médio

- ▶ Tomamos todos os **desvios absolutos** com relação a alguma medida de posição central (média ou mediana).
- ▶ Calculamos a **média** destes desvios.
- ▶ Uma medida alternativa é o **desvio absoluto mediano** em que em vez de calcular a média dos desvios absolutos calculamos a mediana.

$$DAM_{MÉDIA} = \frac{1}{n} \sum_{i=1}^n |(y_i - \bar{y})|$$

$$DAM_{MEDIANA} = \frac{1}{n} \sum_{i=1}^n |(y_i - md)|$$

# Desvio absoluto médio

## Exemplo

- ▶ Retomando o problema das notas de 10 alunos, em que as notas obtidas foram:

60; 65; 77; 95; 56; 94; 97; 81; 80; 48

- ▶ A média é  $\bar{y} = 75,3$  e a mediana é  $md = 78,5$ .
- ▶ Obtenha o desvio absoluto médio com relação à média e à mediana.

# Desvio absoluto médio

## Exemplo - desvio absoluto médio com relação à média

$$DAM = \frac{1}{10} (|(60 - 75,3)| + |(65 - 75,3)| \dots + |(80 - 75,3)| + |(48 - 75,3)|)$$

$$DAM = \frac{1}{10} (15,3 + 10,3 \dots + 4,7 + 27,3) = 14,44$$

# Desvio absoluto médio

## Exemplo - desvio absoluto médio com relação à mediana

$$DAM = \frac{1}{10} (|(60 - 78,5)| + |(65 - 78,5)| \dots + |(80 - 78,5)| + |(48 - 78,5)|)$$

$$DAM = \frac{1}{10} (18,5 + 13,5 \dots + 1,5 + 30,5) = 14,1$$

# Variância

- ▶ Em vez dos desvios, usa a **soma dos quadrados dos desvios** em relação à média.

$$s^2 = \text{Var}(y) = \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2 = \frac{1}{n-1} \left( \sum_{i=1}^n y_i^2 - \frac{(\sum_{i=1}^n y_i)^2}{n} \right)$$

- ▶ A **variância populacional** ( $\sigma^2$ ): usa apenas  $n$  no denominador e é usada quando temos todos os elementos da população. Caso contrário, calculamos sempre a estimativa **amostral** ( $s^2$ ).
- ▶ A justificativa teórica para isso está relacionada com **estimadores não viciados** e com a **distribuição amostral da média**, tópicos que serão discutidos em inferência estatística.

# Desvio padrão

- ▶ Para ter uma medida de dispersão com a **mesma unidade de medida dos dados originais** definiu-se o **desvio padrão** como a raiz quadrada da variância.

$$s = \sqrt{s^2}$$

- ▶ A **variância** e o **desvio padrão** são **invariantes** com respeito a localização dos dados. Isso significa que, se somarmos ou subtrairmos uma constante em todos os valores, não alteramos a dispersão.

# Lei de Chebyshev

- ▶ Independente da forma da distribuição dos dados e de sua variabilidade, conhecemos a **proporção mínima dos valores contidos em intervalos simétricos em relação à média**:
  - ▶ Pelo menos  $3/4$  (75%) dos valores estão no intervalo  $(\bar{y} - 2s, \bar{y} + 2s)$ .
  - ▶ Pelo menos  $8/9$  (89%) dos valores estão no intervalo  $(\bar{y} - 3s, \bar{y} + 3s)$ .
  - ▶ Pelos menos  $(1 - 1/k^2)$  dos dados estará no intervalo  $(\bar{y} - ks, \bar{y} + ks)$ .

# Variância e desvio padrão

## Exemplo

- ▶ Retomando o problema das notas de 10 alunos, em que as notas obtidas foram:

60; 65; 77; 95; 56; 94; 97; 81; 80; 48

- ▶ A média é  $\bar{y} = 75,3$ .
- ▶ Obtenha o variância e desvio padrão.

# Variância e desvio padrão

## Exemplo

- Primeira maneira:

$$s^2 = \text{Var}(y) = \frac{1}{10 - 1} \left( (60 - 75,3)^2 + (65 - 75,3)^2 + \dots + (80 - 75,3)^2 + (48 - 75,3)^2 \right)$$

$$s^2 = \text{Var}(y) = \frac{1}{9} \left( (-15,3)^2 + (-10,3)^2 + \dots + (4,7)^2 + (-27,3)^2 \right)$$

$$s^2 = \text{Var}(y) = \frac{1}{9} (234,09 + 106,09 + \dots + 22,09 + 745,29) = 302,68$$

$$s = \sqrt{s^2} = \sqrt{302,68} = 17,4$$

# Variância e desvio padrão

## Exemplo

- Segunda maneira:

$$s^2 = \text{Var}(y) = \frac{1}{n-1} \left( \sum_{i=1}^n y_i^2 - \frac{(\sum_{i=1}^n y_i)^2}{n} \right)$$

$$s^2 = \text{Var}(y) = \frac{1}{9} \left( 59425 - \frac{753^2}{10} \right) = \frac{1}{9} (59425 - 56700.9) = 302,68$$

$$s = \sqrt{s^2} = \sqrt{302,68} = 17,4$$

# Coefficiente de variação

- ▶ Medida de variabilidade relativa à média.
- ▶ Quociente do desvio-padrão pela média.
- ▶ **Medida adimensional**, geralmente apresentada na forma de porcentagem.
- ▶ Permite comparar a variabilidade de variáveis de diferentes naturezas

$$CV = 100 \cdot \frac{s}{\bar{y}}$$

# Coeficiente de variação

## Exemplo

- ▶ Retomando o problema das notas de 10 alunos, em que as notas obtidas foram:

60; 65; 77; 95; 56; 94; 97; 81; 80; 48

- ▶ A média é  $\bar{y} = 75,3$  e o desvio padrão é  $s = 17,4$ .
- ▶ Obtenha o coeficiente de variação.

$$CV = 100 \cdot \frac{17,4}{75,3} = 23,11$$

# z-escore

- ▶ O z-escore pode ser visto como uma **medida de variabilidade individual** que nos diz quantos desvios padrões determinada observação está distante da média dos dados.
- ▶ O z-escore é dado por:

$$z_i = \frac{y_i - \bar{y}}{s}$$

## Exemplo

- No problema das notas de 10 alunos, em que as notas obtidas foram:

60; 65; 77; 95; 56; 94; 97; 81; 80; 48

os z-escores para cada nota seriam:

$-0,8794$ ;  $-0,5920$ ;  $0,0977$ ;  $1,1323$ ;  $-1,1093$ ;  $1,0749$ ;  $1,2473$ ;  $0,3276$ ;  $0,2702$ ;  $-1,5692$

# Dispersão para variáveis qualitativas


- ▶ Para variáveis qualitativas a **moda** é a única medida de posição que faz sentido.
- ▶ Como medida de dispersão, a ideia de **entropia** pode ser usada.
- ▶ Uma proposta, chamada de **índice de Shannon**, é dada por:

$$H = - \sum_{i=1}^S f_i \ln(f_i)$$

- ▶ Em que  $S$  representa o número de categorias da variável e  $f_i$  representa a frequência relativa associada à categoria  $i$ .
- ▶ Quanto mais distante de 0 for o valor de  $H$ , mais heterogênea é a variável.

# Dispersão para variáveis qualitativas


Qual é o mais homogêneo? Qual é o mais heterogêneo?



|   | $f_{r1}$ | $f_{r2}$ | $f_{r3}$ | $f_{r4}$ | $f_{r5}$ |
|---|----------|----------|----------|----------|----------|
| A | 0.96     | 0.01     | 0.01     | 0.01     | 0.01     |
| B | 0.10     | 0.10     | 0.60     | 0.10     | 0.10     |
| C | 0.10     | 0.30     | 0.10     | 0.20     | 0.30     |
| D | 0.20     | 0.20     | 0.20     | 0.20     | 0.20     |

# Dispersão para variáveis qualitativas

Qual é o mais homogêneo? Qual é o mais heterogêneo?



|   | $f_{r1}$ | $f_{r2}$ | $f_{r3}$ | $f_{r4}$ | $f_{r5}$ | H     |
|---|----------|----------|----------|----------|----------|-------|
| A | 0.96     | 0.01     | 0.01     | 0.01     | 0.01     | 0.223 |
| B | 0.10     | 0.10     | 0.60     | 0.10     | 0.10     | 1.228 |
| C | 0.10     | 0.30     | 0.10     | 0.20     | 0.30     | 1.505 |
| D | 0.20     | 0.20     | 0.20     | 0.20     | 0.20     | 1.609 |

# Desvio, variância, desvio padrão, coeficiente de variação, entropia

- ▶ Amplitude, desvio absoluto médio, variância e desvio padrão são **sensíveis a valores extremos**. Variância e desvio padrão ainda mais por serem baseados nos desvios quadráticos.
- ▶ **Variância** e **desvio padrão** tem **propriedades favoráveis**.
- ▶ O **desvio absoluto mediano da mediana** é uma medida que **não é influenciada**, assim como variâncias e desvios padrões aparados.
- ▶ Quando a distribuição dos dados é **simétrica** estas medidas tendem a convergir.
- ▶ O **coeficiente de variação** permite comparar a variabilidade de variáveis em **diferentes escalas**.
- ▶ O **z-escore** pode ser usado como uma medida de **variabilidade individual**.
- ▶ Para **variáveis qualitativas** existem medidas específicas, como o **índice de Shannon**.

## O que foi visto:

- ▶ Medidas de dispersão.
  - ▶ Amplitude.
  - ▶ Desvio absoluto médio/mediano.
  - ▶ Variância.
  - ▶ Desvio padrão.
  - ▶ Coeficiente de variação.
  - ▶ z-escore.
  - ▶ Entropia.

## Próximos assuntos:

- ▶ Análises bivariadas.
  - ▶ Qualitativa x qualitativa.
  - ▶ Quantitativa x quantitativa.
  - ▶ Quantitativa x qualitativa.